实验三　MapReduce 编程实验

一、 实验目的

1. 掌握 MapReduce 编程基本思想

2. 学习如何编写 MapReduce 程序

二、 实验内容

1. 熟悉 Hadoop 开发包

直接解压 **Hadoop2.5.1** 压缩包后，可看到如下图所示的目录结构，其中比较重要的目录有 **bin,sbin,etc,lib,share** 等，下面分别简要介绍这几个目录的作用。

- **bin,sbin**：包含一些运行 **hadoop** 的脚本程序，例如：
  hadoop:最基本且功能最完备的脚本，其它大部分脚本都会调用该脚本
  start-all.sh/stop-all.sh:启动**/**停止所有结点上的 **HDFS** 和 **MapReduce** 相关服务
  start-mapred.sh/stop-mapred.sh:单独启动**/**停止 **MapReduce** 相关服务
  start-dfs.sh/stop-dfs.sh:单独启动**/**停止 **HDFS** 相关服务
  start-yarn.sh/stop-yarn.sh:单独启动**/**停止 **yarn** 相关服务

- **etc**：**hadoop** 配置文件所在目录，例如
  hadoop-env.sh：设置 **hadoop** 总体环境变量
  core-site.xml：设置基础公共库
  hdfs-site.xml：配置分布式文件系统 **HDFS**
  mapred-env.sh;MapReduce 计算框架配置选项
  yarn-site.xml：配置 **hadoop** 管理工具 **yarn** 等

- **lib,libexec**：包含 **hadoop** 运行时依赖的第三方库，主要是 **c** 语言的动态库，在 **hadoop** 启动或者用户提交作业时会自动加载这些库。

- **share:**包含 **doc** 和 **hadoop** 两个文件夹，其中 **doc** 文件夹是 **hadoop** 的 **api** 介绍文件，例如 **html** 等；**hadoop** 文件夹里面是我们开发 **hadoop** 程序所需要

的一些开发包，**hadoop** 文件夹结构如下图：

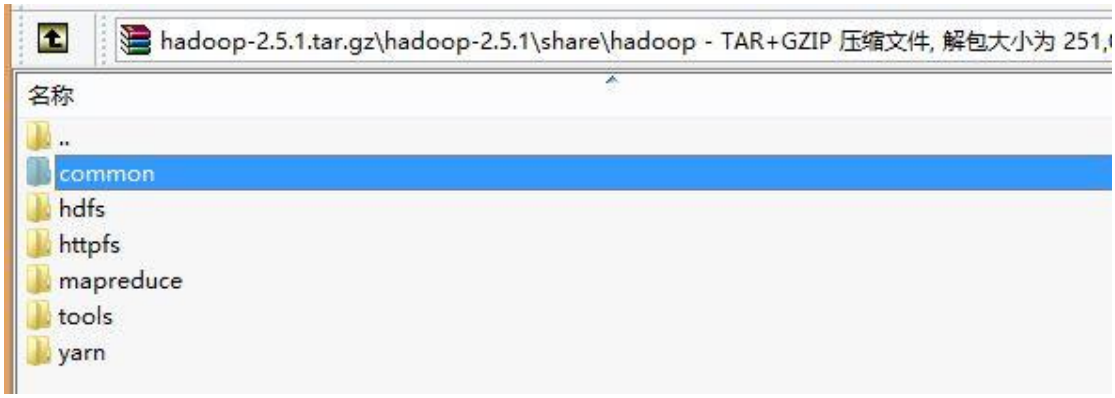

Common：主要文件 **hadoop-common-2.5.1.jar**，包含一些基础公共库

Hdfs：主要文件 **hadoop-hdfs-2.5.1.jar**，包含分布式文件系统操作 **HDFS** 操作相关的类库

Mapreduce：**hadoop-mapreduce-client-core-2.5.1.jar**，包含 **mapreduce** 框架相关的类库

这个程序中我们只需要 **hadoop-common-2.5.1.jar** 和 **hadoop-mapreduce-client-core-2.5.1.jar** 两个 **jar** 包。

2. 编写 MapReduce 程序

详见附件

3. 调试和运行 MapReduce 程序

详见遇到的问题及解决方法部分

4. 完成布置的作业

三、 实验过程

1. 在 Eclipse 中引入 hadoop 开发包

首先可以在 Eclipse 中新建一个工程，例如 SearchLogAnalyze，然后在工程中引入 Hadoop 开发包。可以按该步骤引入相关包：右键工程—> Build Path—>Configure Build Path,然后通过添加 Jars 引入相关包。

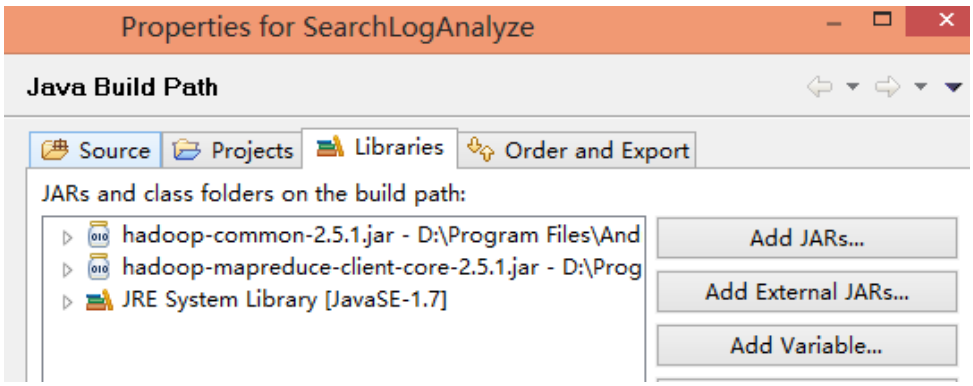

添加库成功后，在工程中的 Referenced Libraries 中可以查看到这些 jar 包。

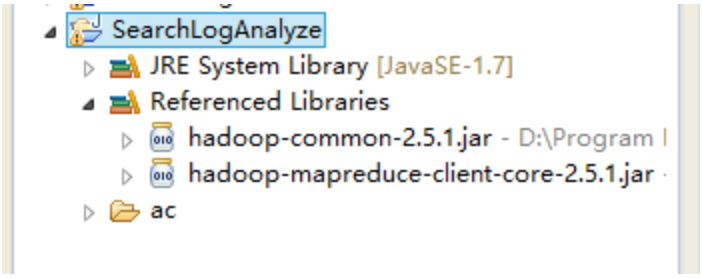

2. 编写 MapReduce 程序

1）Log.java

Log 类的类视图如下：其中红色表示私有，绿色表示公有

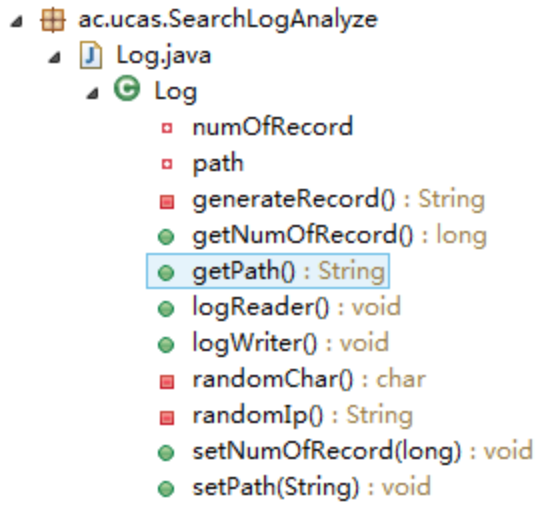

成员变量：

- **numOfRecord**：检索记录的条目，即检索次数
- **path**：保存检索日志的文件路径

成员方法：

- **get/set**：成员变量的获取器和设置器
- **randomIp()**：随机生成一个 **ip** 地址
- **randomChar()**：随机生成一个字符，包括大小写字母和数字
- **generateRecord()**：随机生成一次检索记录
- **logWriter()**：生成检索日志，并写入 **HDFS** 文件中
- **logReader()**：从 **HDFS** 中读取检索日志

2）SearchLogAnalyze.java

SearchLogAnalyze 类视图如下：

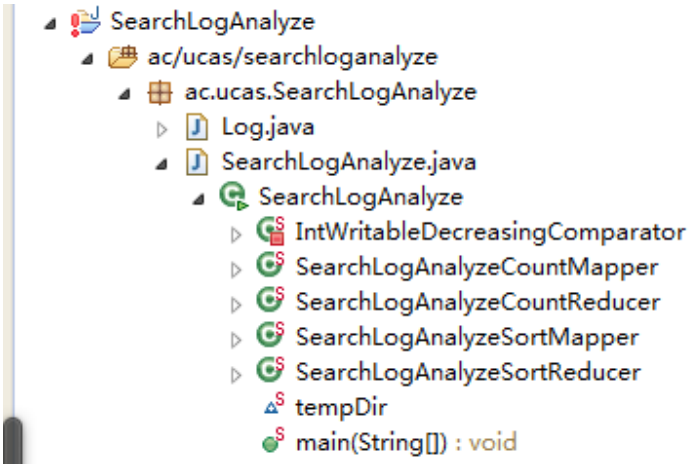

- **IntWritableDecreasingComparator**：降序比较器，用于第二个 **job Map** 后的 **sort** 阶段，使得 **reduce** 输出能按照检索次数降序排序
- **SearchLogAnalyzeCountMapper**：第一个作业的 **Mapper**，用于统计检索次数
- **SearchLogAnalyzeCountRecuder**：第一个作业的 **Reducer**，用于将符合检索条件的检索条目写入 **hdfs** 临时文件，作为第二个作业的输入。
- **SearchLogAnalyzeSortMapper**：第二个作业的 **Mapper**，从第一个作业的输出文件中读取符合条件的检索条目，按照检索次数降序排序
- **SearchLogAnalyzeSortReducer**：第二个作业的 **Reducer**，用于交换 **Mapper** 输出的 **key** 和 **value**，使得按照 **query query-times** 键值对输出结果。

各个类的具体实现及解释请查看源程序及其注释。

3. 打包 MapReduce 程序

右击工程**->Export**

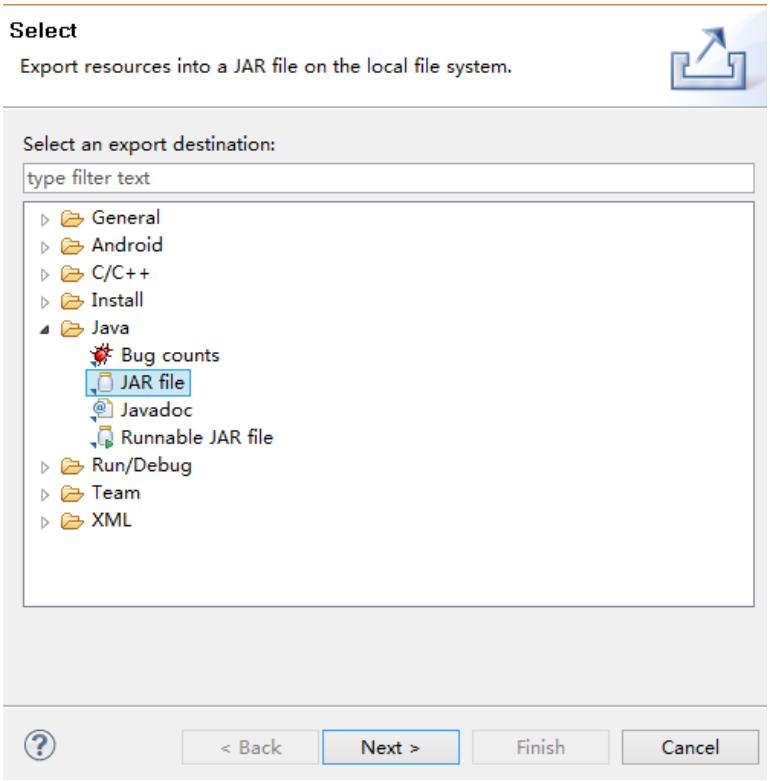

选择 **JAR file**，点击 **next** 后如下图：

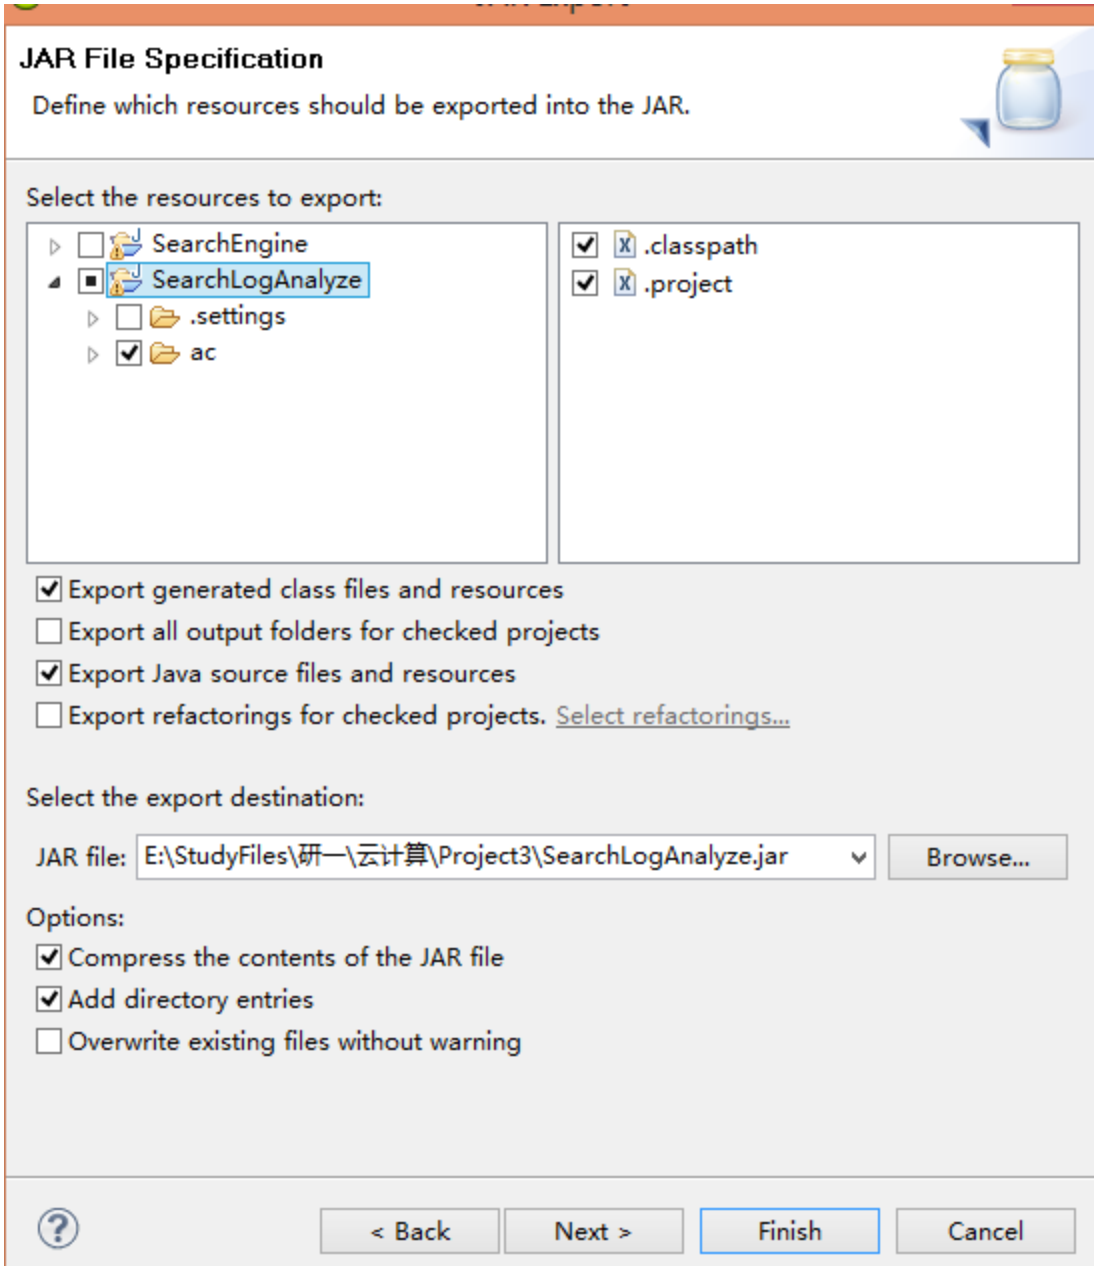

选择需要导出的文件，如果不需要源文件，只需要选中“**Export generated class files and resources**”，否则还需选中“**Export java source file and resouces**”，在 **Select the export destinations** 中填写导出的文件名和所在目录，点击两次 **next**，点击 **Browse** 选择导出 **jar** 包的入口类，如下图：

选择 **SearchLogAnalyze**，点击 **ok->Finish** 即可。

四、 运行结果

1. -h

启动 **hadoop** 后，运行相关命令 **hadoop jar SearchLog.jar -h**,结果如下

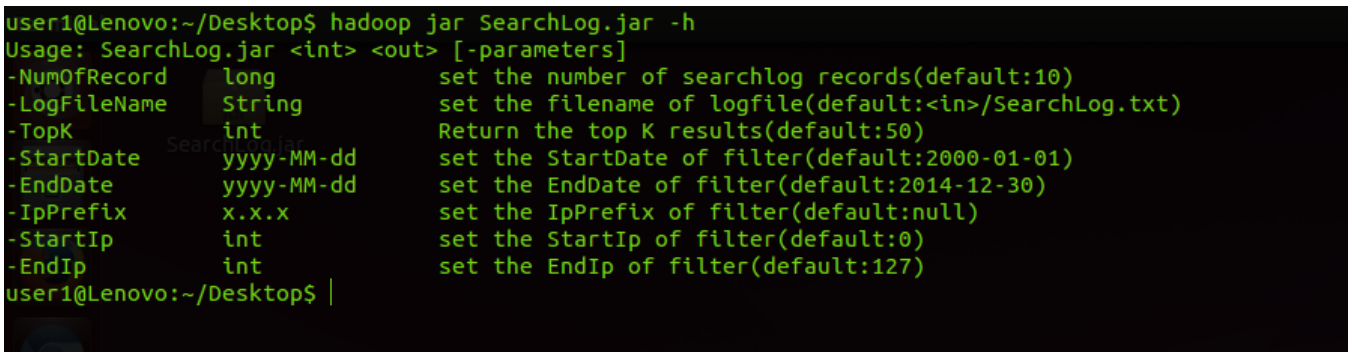

提示需要提供参数输入路径，输出路径和其它一些参数。
先创建 **MapReduce** 输入目录 **SearchLogAnalyze/input**，截图如下：

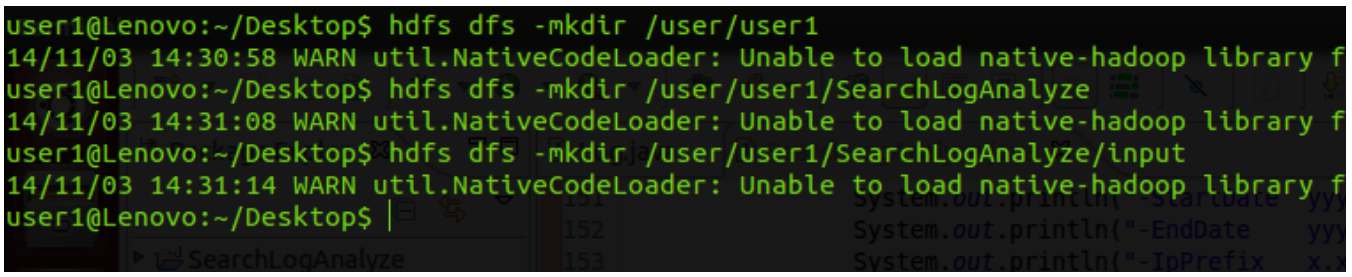

说明:**WARN** 是因为安装的 **hadoop** 本地库是 **64** 位的(可通过运行命令：**file hadoop_home/lib/native/libhadoop.so** 查看)，而运行 **hadoop** 的系统是 **32** 位的，解决方法是下载 **hadoop** 源码，在本地重新编译后，将编译得到的本地库拷贝到相应目录。

2. -NumOfRecord

要对十个查询进行统计，输入命令：
hadoop jar SearchLog.jar SearchLogAnalyze/input SearchLogAnalyze/ouput –NumOfRecord 10
运行结果如下图，根据红色线标记可以看到，启动了一个 **map** 和一个 **reduce** 任务，**map** 和 **reduce** 的记录都是 **10** 个，**CPU** 的运行时间等其他相关信息。

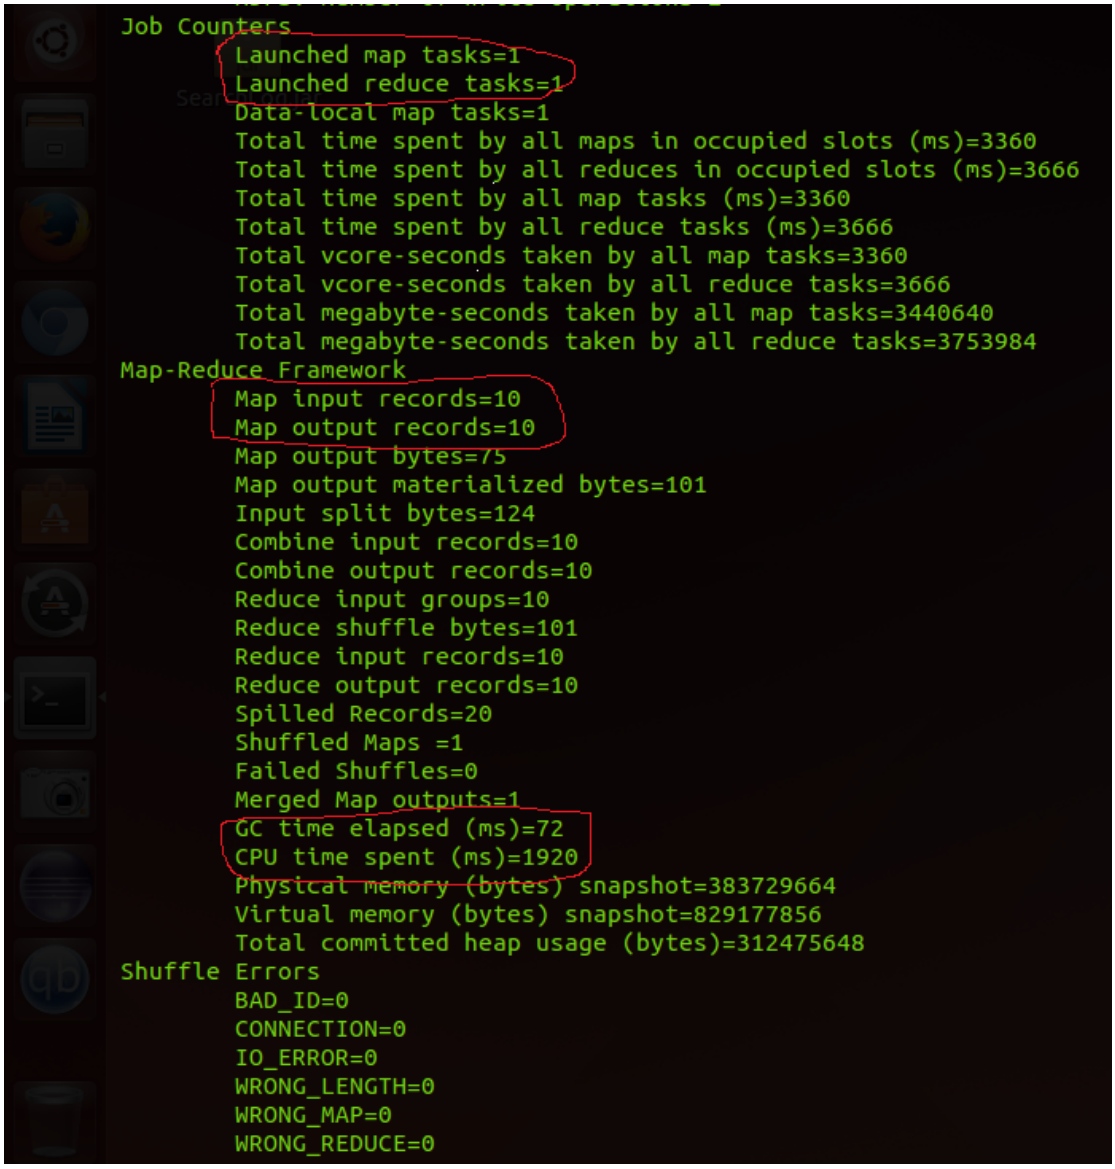

3. -StartDate/-EndDate

先删除之前的 **output** 文件夹和 **input** 文件夹里面的 **SearchLog.txt** 日志文件，下面运行其它测试之前同样。

查找 **10** 个查询记录中在 **2003** 年到 **2010** 年之间的统计信息，输入命令：

hadoop jar SearchLog.jar SearchLogAnalyze/input SearchLogAnalyze/output –NumOfRecord 10 –StartDate 2003-01-01 –EndDate 2010-12-30

```
user1@Lenovo:~/Desktop$ hadoop jar SearchLog.jar SearchLogAnalyze/input SearchLogAnalyze/output -NumOfRecord 10 -StartDate 2003-01-01 -EndDate 2010-12-30
```

运行结果如下：

```
user1@Lenovo:~/Desktop$ hdfs dfs -cat SearchLogAnalyze/input/SearchLog.txt
14/11/03 14:46:36 WARN util.NativeCodeLoader: Unable to load native-hadoop libr
2008-08-21 00:44:33 9XEg 101.125.46.119
2002-09-18 08:36:57 Ynl 25.31.107.1
2008-03-11 08:53:46 g78d 90.11.86.78
2006-05-09 15:20:50 i9 74.84.54.78
2006-09-05 19:05:16 ZkPh 108.89.28.124
2012-11-28 15:28:23 El 113.0.55.115
2009-02-04 05:25:45 K0 51.7.16.2
2001-01-27 06:14:23 7to0 24.53.94.31
2000-04-20 04:47:03 1Mx5 114.125.26.106
2003-04-23 02:56:55 8X 61.45.73.44
user1@Lenovo:~/Desktop$ hdfs dfs -cat SearchLogAnalyze/output/part-r-00000
14/11/03 14:46:44 WARN util.NativeCodeLoader: Unable to load native-hadoop libr
i9      1
g78d    1
ZkPh    1
K0      1
9XEg    1
8X      1
user1@Lenovo:~/Desktop$
```

SearchLog.txt 里面记录了随机生成的 **10** 次查询，**part-r-00000** 输出文件中显示了在 **2003** 年到 **2010** 年范围内的五个检索记录。

4. -StartIp/-EndIp

查询 **10** 个检索记录中 **ip** 地址的最后一部分在范围 **50** 到 **100** 的部分，输入命令：

hadoop jar SearchLog.jar SearchLogAnalyze/input SearchLogAnalyze/output –NumOfRecord 10 –StartIp 50 -EndIp 100

```
user1@Lenovo:~/Desktop$ hadoop jar SearchLog.jar SearchLogAnalyze/input SearchLogAnalyze/output -NumOfRecord 10 -StartIp 50 -EndIp 100
```

运行结果如下：

```
user1@Lenovo:~/Desktop$ hdfs dfs -cat SearchLogAnalyze/input/SearchLog.txt
14/11/03 14:49:16 WARN util.NativeCodeLoader: Unable to load native-hadoop
2003-11-05 19:58:42 jK 69.47.11.27
2005-10-20 15:53:52 fXTc 16.123.56.10
2006-03-21 15:58:57 d 109.64.125.24
2013-09-18 02:32:26 Oa 52.51.34.2
2011-09-13 03:30:12 v0 59.49.110.49
2004-10-25 18:18:41 en 92.112.84.111
2004-09-23 12:48:28 oq 52.62.21.39
2003-10-10 22:38:29 LQ 69.87.7.22
2005-06-06 03:56:27 e 15.114.13.45
2009-05-22 04:38:30 ircG 24.54.79.91
user1@Lenovo:~/Desktop$ hdfs dfs -cat SearchLogAnalyze/output/part-r-00000
14/11/03 14:49:23 WARN util.NativeCodeLoader: Unable to load native-hadoop
ircG    1
user1@Lenovo:~/Desktop$
```

5. -IpPrefix

统计 **10** 个查询中 **ip** 前缀是 **127.127.127** 的查询，输入命令：

hadoop jar SearchLog.jar SearchLogAnalyze/input SearchLogAnalyze/output –NumOfRecord 10 –IpPrefix 127.127.127

```
user1@Lenovo:~/Desktop$ hadoop jar SearchLog.jar SearchLogAnalyze/input SearchLogAnalyze/output -NumOfRecord 10 -IpPrefix 127.127.127
```

运行结果如下：

```
user1@Lenovo:~/Desktop$ hdfs dfs -cat SearchLogAnalyze/input/SearchLog.txt
14/11/03 14:51:49 WARN util.NativeCodeLoader: Unable to load native-hadoop
2001-02-20 20:54:41 lQKt 122.116.74.18
2008-07-06 22:23:11 nv 50.114.0.78
2013-11-25 03:30:05 vOO 36.124.25.74
2006-02-11 20:58:49 A9M 78.5.74.14
2011-03-11 00:45:30 G 19.5.39.88
2008-02-07 18:13:13 n 57.98.89.108
2006-08-03 08:33:09 q 55.122.122.41
2006-06-20 22:13:24 K4hH 81.110.64.2
2000-08-07 22:00:53 ZV 17.19.88.119
2006-09-11 07:13:26 J 121.44.53.77
user1@Lenovo:~/Desktop$ hdfs dfs -cat SearchLogAnalyze/output/part-r-00000
14/11/03 14:51:56 WARN util.NativeCodeLoader: Unable to load native-hadoop
user1@Lenovo:~/Desktop$
```

在上面的 **10** 次检索中，没有 **ip** 前缀是 **127.127.127** 的。

6. -TopK

统计 **1000** 个查询中出现次数最多的 **10** 个，运行命令：

hadoop jar SearchLog.jar SearchLogAnalyze/input SearchLogAnalyze/output –NumOfRecord 1000 –TopK 10

```
user1@Lenovo:~/Desktop$ hadoop jar SearchLog.jar SearchLogAnalyze/input SearchLogAnalyze/output -NumOfRecord 1000 -TopK 10
```

结果如下：

```
user1@Lenovo:~/Desktop$ hdfs dfs -cat SearchLogAnalyze/output/part-r-00000
14/11/03 14:54:03 WARN util.NativeCodeLoader: Unable to load native-hadoop
r       10
D       10
G       9
O       8
Z       8
c       8
d       7
n       7
X       7
j       7
user1@Lenovo:~/Desktop$
```

五、 遇到的问题及解决方法

1. conf.addResource()路径

- 错误

使用 **conf.addResource(“path of xml file”)**时，
context.getConfituration().get(“parameter”)总是返回 **null**。

- 原因

”path of xml file”路径不对，如果是绝对路径的话应该是**/user/$username/…/”,**而

相对路径是相对于**/user/$username** 的。

- 解决方法

  1：设置正确的路径

  2：使用 **conf.set("parameter name","value")**，这里采用了这个方法

2. writeChars()乱码

- 错误

  使用 **writeChars()**向 **HDFS** 文件写入数据后，使用 **hdfs dfs -cat** 命令查看不会乱码，但是 **cpToLocal** 和 **Log.logReader()**中都是乱码

- 原因

  没有设置正确的编码，**cpToLocal** 和 **FileSystem** 读取文件时编码和 **writeChars()** 不同。

- 解决方法

  指定读写编码，源代码如下：（红色标记部分）

```
public void logWriter() throws IOException{
        FileSystem fs = FileSystem.get( new Configuration() );
        FSDataOutputStream fos = fs.create(new Path(getPath()),true);
        Writer out = new OutputStreamWriter(fos,"utf-8");
        for(long i = 0; i < numOfRecord; i++){
            out.write(generateRecord() + "\n");
        }
        out.close();
        fos.close();
    }
    /*读取日志文件到stdout*/
    public void logReader() throws IOException{
        FileSystem fs = FileSystem.get(new Configuration());
        FSDataInputStream fis = fs.open(new Path(getPath()));
        InputStreamReader isr = new InputStreamReader(fis,"utf-8");
        BufferedReader br = new BufferedReader(isr);
        String line = "";
        while((line = br.readLine()) != null){
            System.out.println(line);
        }
        br.close();
        isr.close();
        fis.close();
        }
```

六、 实验分工

在做这个实验之前，我们先认真复习了老师的讲课内容，在此基础上大家分别通过网络或者图书，更加深入地了解了MapReduce作业的整个流程，尤其是map，shuffle，combine，sort和reduce各个阶段的具体流程。通过mapreduce的学习，完成了实验的设计，代码编写，调试和运行，最后撰写实验报告。

- 罗远浩：设计Log类和SearchLogAnalyze类，并完成代码编写。

- 薛杰瑜：对程序进行调试，运行并做记录
- 张慧玲：撰写实验报告和 **PPT**

七、 心得和体会

- 罗远浩：通过这个实验，我加深了对Hadoop的了解，主要是开发包的目录结构；另外对MapReduce程序的总体架构和流程有了更清楚的认识；同时，我也更加认识到在解决一个项目时团队合作的重要性。通过团队合作，不仅能提高项目完成的效率和质量，也能锻炼我们协调和沟通的能力，为我们以后进行大项目的开发积累了宝贵的经验。
- 薛杰瑜：掌握 MapReduce 编程基本思想，初步学习了编写 MapReduce 的简单程序。熟悉了在 linux 环境下的 hadoop 平台，和 MapReduce 开发环境
- 张慧玲：**MapReduce** 的设计目标是方便编程人员在不熟悉分布式并行编程的情况下,将自己的程序运行在分布式系统上。当前的软件实现是指定一个 **Map**（映射）函数，用来把一组键值对映射成一组新的键值对，指定并发的 **Reduce**（化简）函数，用来保证所有映射的键值对中的每一个共享相同的键组。在此次实验过程中，我们学习了 **mapreduce** 代码的编写，对 **mapreduce** 有了一定的了解，虽然在实验中也遇到了困难，但每个困难都是思维的再一次创新。
- 总结：通过这个实验，大家都有所收获：学识上，通过实验，把老师课上讲的东西实践一下，加深了对课堂知识的理解和掌握；团队协作上，大家更加懂得了在一个项目中和他人合作交流的重要性，锻炼了我们的表达，沟通和协调能力。

罗远浩**(2014E8013261184)**
薛杰瑜**(2014E8013261174)**
张慧玲**(201428018743021)**

2014-11-04